

위치 정보 기반 그래프 클러스터링을 위한 엔트로피 가중 적응형 라벨 전파 기법

Entropy-Guided Adaptive Label Propagation for Location-Aware Graph Clustering

요약

현재 소셜 네트워크 내의 그래프 클러스터링은 대개 구조적 연결 정보에만 의존하며, 노드의 공간적 위치를 간과한다. 본 연구는 엔트로피 기반 적응형 가중치를 도입하여 구조·공간 유사도를 결합한 학습 없는 클러스터링 알고리즘을 제안한다. 각 노드의 위치로부터 공간적 유사도를 계산하고, 이웃 라벨의 엔트로피를 바탕으로 구조적 신뢰도에 따라 유사도 결합 비율을 조정한다. 실험 결과, 기존 방법과 유사한 모듈러리티와 컨덕턴스를 유지하면서 실루엣 점수를 높이며, 시각적 분석을 통해 국지화된 커뮤니티를 효과적으로 포착함을 확인하였다.

1. 서론

그래프 클러스터링은 소셜 네트워크 내에 숨겨진 커뮤니티를 식별하는 핵심 기법으로 활용된다. Label Propagation(LP)[1]과 Louvain[2]과 같은 고전적 방법들은 순전히 구조적 연결에만 의존하기 때문에, 그래프가 희소하거나 노이즈가 많은 경우에는 성능이 저하되는 한계가 있다. Graph Neural Network(GNN) 기반 접근법[3]은 학습 가능한 집계를 통해 구조 정보와 노드 특징을 통합할 수 있지만, 훈련 과정과 풍부한 노드 속성이 필요하므로 경량의 비지도 학습 환경에서는 활용이 제한적이다.

위치 기반 소셜 네트워크에서는 사용자의 행동이 공간적 체인 정보에 의해서도 영향을 받지만, 기존 방법들은 이를 종종 간과하거나 복잡한 궤적 기반 모델(trjectory-based models)에 의존해 왔다.

본 연구에서는 엔트로피 기반 유사도 결합 방식을 도입하여 기존 LP를 확장한 학습이 필요 없는 클러스터링 알고리즘을 제안한다. 제안한 방법은 구조적 신호의 불확실성이 높은 경우 최근 위치 데이터를 적극 활용하고, 구조적 신호가 명확할 때는 그래프의 토폴로지를 우선적으로 반영하도록 설계되었다.

Brightkite 데이터셋을 대상으로 본 방법을 평가한 결과, 본 방법은 공간적으로 일관된 클러스터를 형성하면서도 모듈러리티와 컨덕턴스 측면에서 기존 기법과 경쟁력 있는 성능을 달성하였다. 본 접근법은 학습 과정에 의존하지 않으며, 해석 가능성과 확장성이 우수해 훈련이 필요한 모델에 대한 실용적인 대안을 제시한다.




그림 1: LP 방식의 한계

2. 문제 정의

목표. 본 연구에서는 소셜 네트워크 서비스를 이용자 및 이들의 연결 관계를 기반으로 무방향 그래프 $G = (V, E)$ 로 정의한다. 각 사용자 노드 $v_i \in V$ 는 최근 체크인에 기반한 최신 위치 l_i 를 가진다. 목표는 구조적 근접성과 공간적 지역성을 동시에 보존

하면서 노드를 $C = C_1, \dots, C_k$ 로 클러스터링하는 것이다.

하이브리드 유사도 함수. 구조 정보에만 의존하는 LP의 한계를 극복하기 위해, 다음과 같은 하이브리드 유사도 함수를 정의한다. 구조적 유사도는 이웃 노드 집합 간의 Jaccard 유사도를 사용하며, 기하학적 유사도는 위치 임베딩 간의 코사인 유사도를 사용한다.

$$\text{sim}_{ij} = \alpha_{ij} \cdot \text{sim}_{\text{structure}}(i, j) + (1 - \alpha_{ij}) \cdot \text{sim}_{\text{geometry}}(i, j) \quad (1)$$

엔트로피 기반 가중치 가중치 $\alpha_i \in [0, 1]$ 는 노드 i 주변의 구조적 일관성에 대한 신뢰도를 나타내며, 이웃 노드들의 라벨 분포 엔트로피를 통해 계산된다. 낮은 엔트로피는 구조적 신호가 명확함을 의미하며, α_i 값이 높아질수록 구조 정보에 대한 의존도가 증가한다. 반면, 엔트로피가 높을수록 α_i 값이 낮아져 공간적 유사도에 더 큰 가중치를 부여한다.

$$H_i = - \sum_{l \in \mathcal{L}} p_i(l) \log p_i(l), \quad \alpha_i = 1 - \frac{H_i}{\log |\mathcal{L}|}, \quad \alpha_{ij} = \frac{(\alpha_i + \alpha_j)}{2} \quad (2)$$

이와 같이 본 방법은 각 노드의 지역 엔트로피에 따라 구조적 유사도와 공간적 유사도를 적응적으로 결합하여 라벨 전파를 수행한다.

3. 알고리즘

고전적 라벨 전파 고전적 라벨 전파(Label Propagation, LP)는 각 노드가 이웃 노드들 중 가장 빈도가 높은 라벨을 반복적으로 채택하는 빠른 비지도 학습 알고리즘이다. 효율적이지만, 순수하게 구조 정보에만 의존하기 때문에 그래프가 희소하거나 노이즈가 많은 경우 견고성이 저하되는 한계가 있다.

하이브리드 유사도를 이용한 적응형 라벨 전파. 본 연구에서는 유사도 기반 가중 투표 방식을 도입하여 LP를 확장한다. 각 노드는 자신과 이웃 간의 하이브리드 유사도 점수 sim_{ij} (식 (1))에 기반하여 라벨을 갱신한다. 여기서 sim_{ij} 는 구조적 유사도와 공간적 유사도를 결합하며, 적응적 가중치 α_{ij} 는 해당 노드의 지역적

구조 신뢰도를 반영한다(섹션 2 참고). 구조적 신호가 불확실한 노드(엔트로피가 높은 노드)는 공간적 유사도에 더 의존하며, 반대로 구조가 안정적인 노드(엔트로피가 낮은 노드)는 구조 정보에 더 큰 가중치를 부여한다.

$$L_i^{(t+1)} = \arg \max_{l \in \mathcal{L}} \sum_{j \in N(i)} \text{sim}_{ij} \cdot \mathbb{I}[L_j^{(t)} = l]$$

알고리즘 단계.

1. **초기화:** 각 노드에 고유한 라벨을 할당하고, 위치 임베딩을 추출한다.
2. **유사도 사전 계산:**
 - 모든 엣지에 대해 구조적(Jaccard) 유사도와 기하학적(코사인) 유사도를 계산한다.
3. **반복적 라벨 전파:**
 - 각 노드에 대해 이웃 라벨 분포와 엔트로피를 계산한다.
 - $\alpha_i = 1 - \frac{H_i}{\log |\mathcal{L}|}$ 및 $\alpha_{ij} = \frac{(\alpha_i + \alpha_j)}{2}$ 를 계산한다.
 - 식 (1)을 이용하여 sim_{ij} 를 계산한다.
 - 가중 다수결 투표로 각 노드의 라벨을 갱신한다.
4. **수렴:** 라벨 할당이 안정될 때까지 반복한다.

복잡도. 각 반복(iteration)은 유사도 갱신과 라벨 전파를 위해 $O(n \cdot d)$ 의 연산량을 소요하며, 여기서 n 은 노드 수, d 는 평균 차수이다. 총 복잡도는 $O(n \cdot d \cdot T)$ 이다.

Algorithm 1: 엔트로피 기반 적응형 라벨 전파 (ALP)

Data: 그래프 $G = (V, E)$, 위치 $\{l_i\}$
Result: 라벨 $\{L_i\}$

```

1 foreach  $i \in V$  do
2    $L_i \leftarrow i$ ;
3 foreach  $(i, j) \in E$  do
4    $\text{sim}_{\text{str}}(i, j), \text{sim}_{\text{geo}}(i, j)$  계산;
5 while 라벨이 수렴하지 않음 do
6   foreach  $i \in V$  do
7     이웃 라벨로부터  $H_i$  계산;
8      $\alpha_i \leftarrow 1 - \frac{H_i}{\log |\mathcal{L}|}$ ;
9   foreach  $(i, j) \in E$  do
10     $\alpha_{ij} \leftarrow \frac{(\alpha_i + \alpha_j)}{2}$ ;
11     $\text{sim}_{ij} \leftarrow \alpha_{ij} \cdot \text{sim}_{\text{str}} + (1 - \alpha_{ij}) \cdot \text{sim}_{\text{geo}}$ ;
12  foreach  $i \in V$  do
13     $L_i \leftarrow \arg \max_l \sum_{j \in N(i)} \text{sim}_{ij} \cdot \mathbb{I}[L_j = l]$ ;

```

4. 실험

제안한 방법론의 유효성을 평가하기 위해 다양한 실험을 수행하였으며, 이를 통해 다음과 같은 평가 질문(Experimental Question, EQ)에 대한 답을 제시하고자 한다.

- **EQ1. 모델 성능 평가:** 다양한 클러스터링 지표를 통해 제안 모델의 공간적 일관성과 군집 품질의 균형을 입증한다.
- **EQ2. 모델 효율성 평가:** 실행 시간 및 메모리 사용량 비교를 통해 제안 모델의 계산 효율성과 경량성을 입증한다.
- **EQ3. 적응 동작 평가:** 반복에 따른 라벨 수 및 가중치 분식을 통해 구조-공간 신호 간의 동적 조절 능력을 입증한다.
- **EQ4. 공간 정합성 평가:** 클러스터링 결과 시각화를 통해 제안 모델의 지리적 응집력 및 위치 인식 능력을 입증한다.

데이터셋. 본 연구에서는 제안한 모델을 평가하기 위해 SNAP 저장소의 **Brightkite** 데이터셋을 사용하였다. 이 데이터셋은 사용자 체크인 정보와 친구 관계를 포함하는 위치 기반 소셜 네트워크 그래프 데이터로, 총 58,228개의 노드와 214,078개의 무방향 엣지로 구성된다.

기준선 및 평가 지표. 본 연구에서는 제안한 방법을 Label Propagation, Louvain과 비교하였다. 클러스터링 성능 평가는 Modularity, Conductance, Silhouette Score, 라벨 수를 기준으로 수행하였다.




그림 2: EQ1. 10회 반복 클러스터링 지표 평균

EQ1. 클러스터링 지표 비교. 그림 2은 LP, Louvain, ALP의 10회 실행 평균 결과를 요약한 것이다. Louvain은 가장 높은 모듈러리티(0.686)를 달성하여 군집 내부의 밀도가 높음을 나타냈으나, 가장 낮은 컨덕턴스(0.035)를 기록해 클러스터가 상대적으로 고립되어 있음을 시사한다. LP와 ALP는 각각 0.960, 0.913의 높은 컨덕턴스를 보여 더 연결된 커뮤니티를 형성한다. 실루엣 점수는

Louvain이 가장 높으며, ALP의 상대적으로 낮은 값은 기하학적 응집성보다는 구조-공간 균형을 중시하는 특성을 반영한다. 클러스터 수 측면에서는 LP가 과도한 세분화(3466.5)를 보였으며, Louvain은 과소 세분화(718)를 나타냈다. ALP는 중간 수준의 균형(968.2)을 달성하여, 구조적·공간적 단서를 적응적으로 결합해 일관성 있고 적절히 세분화된 클러스터를 형성함을 확인할 수 있었다.

방법	실행 시간 (초)	메모리 (MB)
Label Propagation	306.0	29.3
Louvain	184.6	95.1
Adaptive Label Propagation	553.5	29.4

표 1: EQ2. 10회 실행 평균 실행 시간과 메모리 사용량

EQ2. 실행 시간 및 메모리 효율성. 표 1은 10회 실행의 평균 실행 시간과 메모리 사용량을 나타낸다. 모든 실험은 동일한 CPU 환경에서 수행되었다. ALP는 매 반복마다 하이브리드 유사도와 엔트로피 기반 가중치를 동적으로 재계산하기 때문에 가장 긴 실행 시간을 보인다. 반면, LP와 Louvain은 각각 정적 또는 모듈러리티 기반 갱신 방식을 사용한다. 그러나 ALP는 메모리 효율성이 높아(29.4MB), LP와 유사하며 Louvain보다 훨씬 가볍다. 이러한 특성은 메모리 제약이 있으면서도 일정 수준의 실행 시간이 허용되는 환경에서 ALP가 적합함을 시사한다.




그림 3: EQ3. 반복에 따른 라벨 수와 평균 α 의 변화


EQ3. 반복에 따른 라벨 수와 평균 α 의 변화. 그림 3은 반복 과정에서 클러스터 수와 평균 α 값의 변화를 나타낸다. 초기에는 각 노드가 고유 라벨을 가지며(총 5,822개), 빠른 수렴 과정을 거쳐 반복 10회 시점에는 약 963개로 감소한다. 평균 α 는 초기에는 높은 값을 보이다가 초반 반복에서 일시적으로 감소한 후(0.91), 이후 점차 증가하는 경향을 보인다. 이는 초기 단계에서는 구조적 불확실성을 해소하기 위해 공간적 단서를 더 많이 활용하고, 군집이 안정되면 다시 구조 정보에 대한 의존도를 높이는 동적

특성을 반영한다. 이러한 변화는 엔트로피 기반 가중치가 구조적 신호와 공간적 신호를 효과적으로 균형 있게 결합함을 보여준다.

EQ4. 시각화. 사용자 체크인 좌표를 기반으로 클러스터링 결과를 시각화하여 공간적 일관성을 평가하였다.

기존 방법 — Label Propagation과 Louvain

그림 4은 LP와 Louvain이 순수하게 구조적 연결에만 의존하기 때문에, 실제 지리적 분포와 무관하게 분산된 노드들이 동일한 클러스터로 묶이는 경향이 있음을 보여준다. 이로 인해 서로 멀리 떨어진 지역의 사용자들이 그래프상의 단축 경로(shortcut) 때문에 같은 라벨로 할당되는 현상이 발생하며, 결과적으로 공간적 일관성이 낮은 클러스터가 형성된다.




(a) Label Propagation (전세계)

(b) Louvain (전세계)


그림 4: 기준선 클러스터링 결과

Adaptive Label Propagation

그림 5은 ALP가 최근 위치 데이터를 활용하여 공간적으로 정렬된 클러스터를 형성함을 보여준다.



(a) Adaptive LP (전세계)




(b) Adaptive LP (유럽)


그림 5: Adaptive LP를 사용한 클러스터링 결과

클러스터 표시

그림 6은 ALP가 공간적으로 응집력 있는 클러스터를 형성하는 능력을 강조하기 위해 주요 영역을 표시한 결과를 보여준다.



(a) Adaptive LP (전세계, 표시)



(b) Adaptive LP (유럽, 표시)

그림 6: Adaptive LP로 탐지된 주요 클러스터

5. 결론

본 연구는 최신 위치와 구조 정보를 엔트로피 기반으로 결합한 학습 없는 경량 그래프 클러스터링 알고리즘을 제안하였다. 제안 모델은 구조 신뢰도에 따라 유사도를 동적으로 조정하며, Brightkite 데이터셋에서 경쟁력 있는 성능과 공간적 응집력을 입증하였다. 향후에는 다양한 유사도 결합 방식과 추가 속성 정보를 활용하여 표현력과 적응성을 확장할 계획이다.

참고 문헌

- [1] U. N. Raghavan, R. Albert, and S. Kumara, "Near linear time algorithm to detect community structures in large-scale networks," *Physical Review E*, vol. 76, no. 3, p. 036106, 2007.
- [2] V. D. Blondel, J.-L. Guillaume, R. Lambiotte, and E. Lefebvre, "Fast unfolding of communities in large networks," *Journal of Statistical Mechanics: Theory and Experiment*, vol. 2008, no. 10, p. P10008, 2008.
- [3] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang, and P. S. Yu, "A comprehensive survey on graph neural networks," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 32, no. 1, pp. 4–24, 2021.